

2023

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

SAĞLIKTA YAPAY ZEKÂ YARIŞMALARI

(Bilgisayarlı Görüyle Tarama Mamografilerinde BI-RADS

Kategorisi ve Meme Kompozisyonu Tahmini Yarışma

Kategorisi)

PROJE DETAY RAPORU

TEKNOFEST
İSTANBUL HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ
TAKIM ID: 178624

YARIŞMA SEVİYESİ

ORTAÖĞRETİM

YÜKSEKÖĞRETİM

İçindekiler

1. Proje Mevcut Durum Değerlendirmesi	3
2. Özgünlük	4
3. Sonuçlar ve İnceleme.....	6
4. Deney ve eğitim aşamalarında kullanılan veri setleri	10
5. Referanslar.....	12



1. Proje Mevcut Durum Değerlendirmesi

İlk rapor olan Proje SunuŞ Raporu hazırlanırken Teknofest'in temin ettiği veri seti kullanılamadığından ötürü kullanılacak algoritmalar teorikte kalmış olup aktif olarak uygulanamamıştır. Bu nedenle Proje SunuŞ Raporu teslim edilip çalışmada kullanılacak veriler temin edildikten sonra eğitim algoritmaları seçimlerinde değişikliklere gidilmiştir. Hazırladığımız Proje SunuŞ Raporunun özgünlük kısmında, hakemlerin puanlaması göz önünde bulundurularak özgünlük konusunda kullanılacak yöntemlerin eksiklikleri ve bazı ölçümelerin yetersiz oldukları fark edilmiştir, özgünlüğün daha iyi uygulanması ve yapılan çalışma başarısının artırılması adına derin öğrenme ve sınıflandırma literatürüne yeni dahil edilmiş güncel yöntemler kullanılarak çalışma problemine çözüm üretme çalışmaları yapılmıştır.

Teknofestin sağlamış olduğu veriler DICOM formatında olduğundan ilk olarak bu veriler JPG formatına çevrilerek eğitime hazır hale getirilmiştir. BMP, PNG gibi resim formatları yerine, görüntüdeki önemli özelliklerini koruyan JPG formatı tercih edilmiştir. Görüntüler başlangıçta 512x512 piksel boyutlarında kullanılmış, daha sonrasında bilgi kaybı olup olmadığı tespit edilmesi amacıyla 2048x2048 piksel ile sonuçları karşılaştırılmıştır.

Verilen görüntüler, eğitimde daha kolay kullanılması için tek bir klasöre taşınmıştır. Taşıma işlemini gerçekleştirirken her bir klasördeki görüntüler klasör adıyla yeniden isimlendirilmiştir. Böylece ileride kullanılacak olan hastaNo bilgileri tutulmuş ve eğitime hazır hale getirilmiştir.

```
deletes = []

for root, dirs, files in os.walk(path):
    for f in files:
        file_path = os.path.join(root, f)
        folder = file_path.split('\\')[-3] # Sınıf klasörü
        del_folder = file_path.split('\\')[-2] # Silinmek istenen klasör
        new_file_path = file_path.replace(f, del_folder + '_' + f) # Resimler id isimleriyle adlandırılıyor
        os.rename(file_path, new_file_path) # Resimlerin gideceği adres
        direction = os.path.join(path, folder)
        deletes.append(os.path.join(direction, del_folder))
        shutil.copy(file_path, os.path.join(direction, f))

deletes = set(deletes)

for x in deletes:
    try:
        shutil.rmtree(x)
    except:
        pass
```

Resim 1. Dosya İşlemlerinde Kullanılan Örnek Kod Parçası

Verilen excel dosyasındaki bilgiler ışığında eğitime bazı verilerin kullanılmasında değişiklikler yapılmıştır. BI-RADS skoru kolonundaki kategori-0 sınıfında yer alan ek değerlendirme tetkiki yapılmalı şeklindeki bulgularda kadran bilgisine sahip olmayan görüntüler eğitime dahil edilmemiştir. Bunun yapılmasındaki amaç kadran bilgisi gerektirmeyen görüntülerde bir belirsizliğin olmayışi ve bu görüntülerin kategori-0'da bulunmaması gerektiğini ön görülmüşdür. Ayrıca BI-RADS 4-5 kategorisinde olan resimlerde de kadran bilgisine sahip olmayan görüntüler eğitime dahil edilmemiştir. Çünkü kötü huylu olmayıp biyopsi gerektirmeyen kadransız görüntüler yapay zeka eğitim modelini yanlış bir şekilde eğitip hastalık belirtisi olmayan görüntüleri hastalıklı şekilde etiketleyecektir [1].

Veriler hakkında ön inceleme yapıldığında sınıflardaki veri sayılarının dengeli bir şekilde dağılmadığı fark edilmiştir. Bazı sınıflardaki görüntülerin sayısı diğerlerinden daha az olduğu

görülmüştür. Dengesiz veri sayılarını içeren sınıfların oluşturduğu veri seti ile eğitim yapılip sonuçlar incelendiğinde, bu sayı dengesizliğinin test sonuçlarını olumsuz etkilediği görülmüştür. Bu probleme çözüm olarak sınıflara özel oranlarla veri çoğaltma yöntemleri kullanılmıştır. Veri çoğaltma işlemlerinin özellikleri özgünlük kısmında detaylı olarak açıklanmıştır. Bu çözüm yöntemine ek olarak Teknofest veri seti ile uyumlu olan Kaggle'daki RSNA yarışması kapsamında paylaşılan veriler, eksik olan sınıf verilerine dahil edilmiştir.

Veri setinde ön işleme aşamalarının tamamlanmasının ardından derin öğrenme mimari tasarımları aşamasına geçilmiştir. Bu kısımda DenseNet, EfficientNet B2 ve B7, GoogleNet, İnception-ResNetV2, VGG16 ve ResNet olmak üzere birçok Transfer Learning mimarisi kullanılarak testler yapılmıştır [2]. Baseline, hiçbir eklenti ve uygulama yapılmadığında test başarısının en yüksek değerinin 58,64'te kaldığı görülürken, ön işleme ve çalışma üzerinde kullandığımız özgün yöntemlerin sonuçlarına bakıldığıda doğruluk başarı değerinin EfficientNet-B2 modeli ile 82,30'a ulaşlığı görülmüştür.

Daha sonrasında eğitimi tamamlanan modellerin sinir ağlarındaki ağırlıklıkları h5 ve pth uzantılı olacak şekilde kaydedilerek ileride de test edilmesi sağlanmıştır. BI-RADS kategori tespitinin başarısını artıracak diğer bir yöntem olarak Ensemble Learning (Topluluk Öğrenmesi) uygulanmıştır. Ensemble Learning'in kullanılmasıyla tespit başarısı artırılarak yapay zeka modelinin daha doğru kararlar vermesi sağlanmıştır [3].

2. Özgünlük

a. Topluluk Öğrenmesi

Yapılan eğitimlerde birçok öğrenme aktarımı modeli denenmiş ve birbirinden farklı sonuçlar elde edilmiştir. Bazı modeller bir sınıfı daha iyi tahmin ederken diğerleri başka bir sınıfı daha iyi tahmin etmektedir. Bu durumda en optimum sonucu elde etmek için Ensemble Learning (Topluluk Öğrenmesi) kullanılmıştır.

Ensemble Learning'de aynı sınıflandırma görevinde birden fazla sınıflandırıcı kullanılmaktadır. Bu yöntemde farklı doğruluk skorlarına sahip sınıflandırıcıların sonuçları farklı karar verme yöntemleri ile (oylama, ortalama vb.) birleştirilmektedir. Böylelikle tek bir sınıflandırıcıdan daha iyi sonuçlar elde etme imkanı bulunmaktadır. Bu çalışmada ağırlıklı ortalama tekniği kullanılmıştır.

b. Düzensiz Verilerin Dengelenmesi

Veri setinde özellikle iki sınıfın veri sayısında dengesizlik olduğu fark edilmiştir. Bu dengesizliği gidermek adına birkaç farklı yöntem uygulanmıştır. İlk olarak diğer sınıflardan fazla olan veriler azaltılmıştır. Bu yöntem ile modelin başarısı artmıştır fakat bilgi kaybı olup modelin daha az hastalık türünü görmesinden dolayı veri çoğaltma yöntemine geçilmiştir.

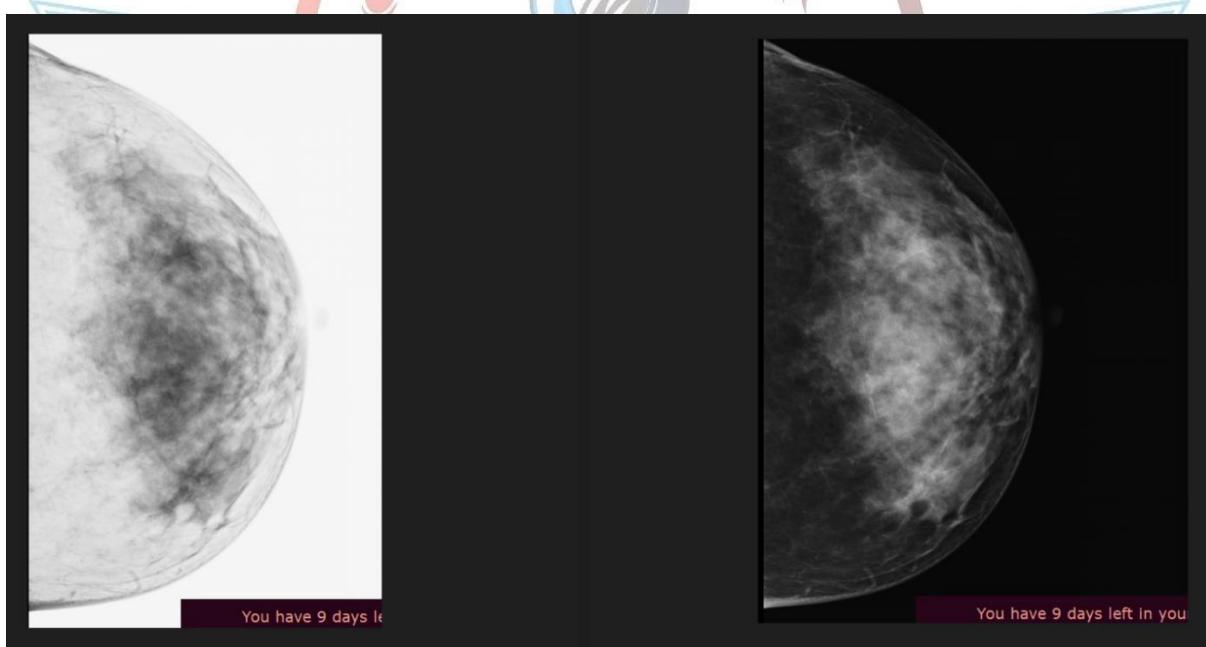
Veri çoğaltma yönteminde bütün verilerde veri çoğaltma işlemi uygulamak yerine azınlık olan sınıfta veri çoğaltma yapılarak çalışmaya özgünlük kazandırılmıştır. Bu şekilde model, daha önceki testlerde iyi tahmin edemediği sınıfları daha doğru tahmin etmeye başlamıştır.

c. Dengelenmiş Ağırlıklarla Eğitim Yapılması

Sınıf dengesizliği olan verilerin eğitiminde sınıflandırıcılar baskın olan sınıfı daha fazla öğrenme eğilimi göstermektedirler. Bu çalışmada BI-RADS1-2 kategorisindeki verilerin çokluğundan ötürü eğitimde aşırı öğrenmeye sebep olmaktadır. Bu tür sorunlara çözüm olarak SMOTE sentetik veri üretme yöntemleri kullanılmaktadır. SMOTE veri kümесinin tamamını giriş olarak alır ama yalnızca azınlık sınıf üzerinde çoğaltma işlemleri yaparak o sınıfın veri yüzdesini artırmaktadır.

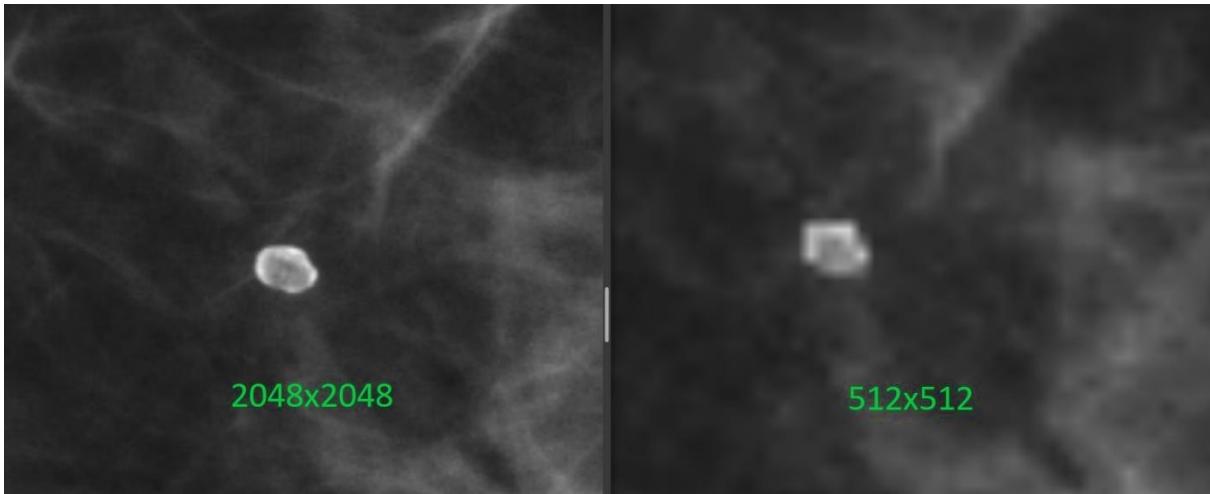
Sentetik veri üretme yöntemleri vektör veriler üzerinde başarılı sonuçlar vermektedir. Derin öğrenmede özellik vektörünün oluşturulduğu flatten katmanındaki dengesiz veriler dengeleme yöntemleri ile ön işlendikten sonra sınıfandrıcının eğitimi tekrar gerçekleştirilir. Çalışmamızda ilk olarak oluşturulan model normal bir şekilde eğitilmiştir, eğitim tamamlandıktan sonra flatten katmanında tespit edilen dengesiz veriler üzerinde dengeleme işlemleri uygulanmıştır son aşamada ise dengelenmiş veriler ile full connected kısmı tekrar eğitilmiştir. Dengeleme işlemleri ile modelin flatten katmanındaki dengesiz veriler düzenlenerek yeni yapılan eğitimdeki sonuçların başarısı artırılmıştır.

d. ReColor-ReSize Karşılaştırma İşlemleri



Resim 2. Görüntülerin Negatiflerinin Alınması

Resim 2'de görüldüğü üzere görüntülerin negatifleri `torchvision.transforms.functional.invert()` fonksiyonundan yararlanarak alınmış ve eğitimler gerçekleştirilmiştir. Daha sonrasında ise iki durumun eğitim sonuçları karşılaştırılmıştır. Sonuç olarak arka planın siyah olduğu durumlarda sonuçların daha başarılı olduğu görülmüştür.



Resim 3. Görüntülerde Yeniden Boyutlandırma İşlemleri

Görüntüler 512x512 boyutlandırıldığında özellik (feature) çıkarma işlemi daha kısıtlı ve az olduğundan 2048x2048 piksel boyutlandırmasıyla yapılan eğitiminin daha başarılı sonuçlar verdiği görülmüştür.

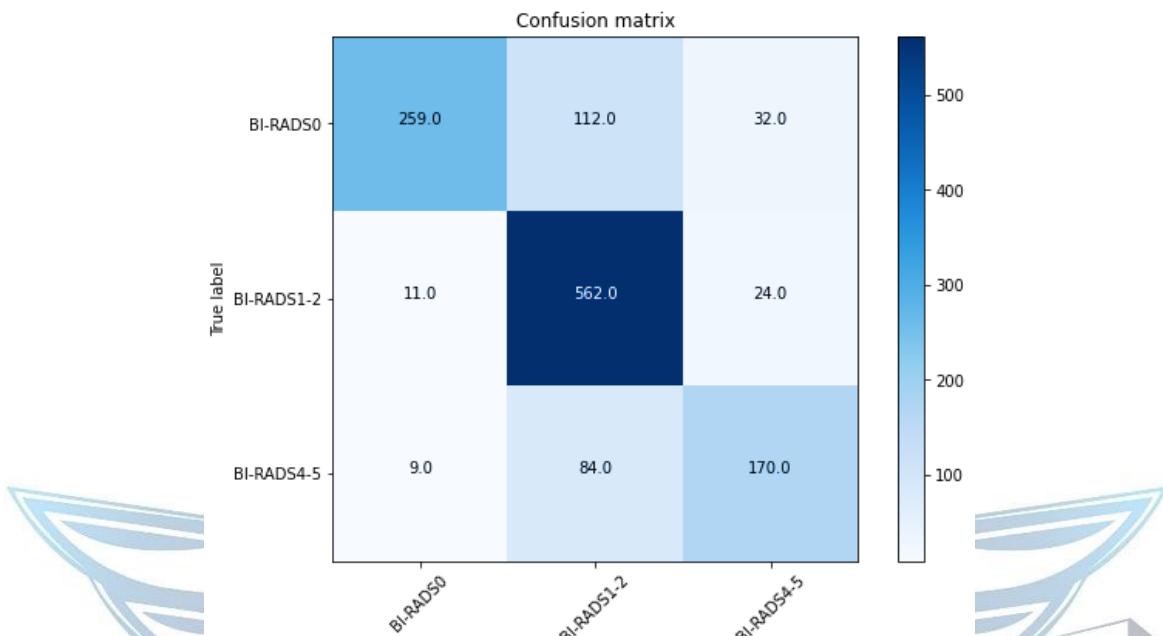
3. Sonuçlar ve İnceleme

MODEL	VAL-ACCURACY	TEST-ACCURACY	TEST-LOSS	RECALL	Precision
BASELINE	57.38	58.64	87.25	54.00	55.00
EfficientNet-B2	84.49	82.30	56.64	77.00	83.00
EfficientNet-B7	83.07	78.46	63.71	74.00	80.75
DenseNet169	83.38	76.16	69.44	67.00	72.50
Inception-ResNet-V2	81.09	73.03	74.80	69.00	72.50
ResNet101	77.45	71.77	83.70	63.00	69.00
VGG16	77.76	68.73	78.68	61.00	59.00
GoogleNet	76.88	70.25	77.27	60.00	61.00

Resim 4. BI-RADS Kategori Tespitindeki Eğitim-Test ve Metrik Sonuçları

Tarama mamografları ile BI-RADS kategori tespitinde EfficientNet-B2, EfficientNet-B7, DenseNet169, InceptionResNet-V2, ResNet101, VGG16 ve GoogleNet olmak üzere toplam 7 farklı öğrenme aktarımı modeli kullanılmıştır. Bütün modeller ortalama 20 epoch ile eğitilmiştir. Veri seti üzerinde ön işleme, veri artırma ve çalışma üzerinde kullandığımız özgün

yöntemler olmadan eğitilen baseline modelin doğruluk oranı 58,64'de kalmıştır. Başarı oranını artırmak üzere yapılan çalışmalardan sonra BI-RADS tespit değeri EfficientNet-B2 modeli ile 82,30'a yükseltilmiştir. En düşük kayıp (loss) değeri 56,64 ile EfficientNet-B2 modelinde sağlanmıştır. Teknofest yarışma başarısı ölçme metriklerinden olan Duyarlılık (Recall) ve Kesinlik'te (Precision) en başarılı olan model sırasıyla 77,00 ve 83,00 değerleri ile EfficientNet-B2 olmuştur.



Resim 5. EfficientNet-B7 modelinin Konfüzyon Matrisi

EfficientNet-B7 modelinin konfüzyon matrisine göre model veriyi %78,46 doğruluk orANIyla tahmin etmiştir. Özellikle BI-RADS1-2 sınıfındaki veri sayısının diğer sınıflara oranla daha fazla olduğu göz önünde bulundurularak eşit dağılmayan unbiased veri kümelerinde modeli değerlendirmek için model doğruluğu başarısının (Accuracy) tek başına yeterli olmadığı rahatlıkla söylenebilmektedir. Bu nedenle diğer metriklerin sonuçlarıyla birlikte modelin yeterliliği değerlendirilmelidir [4].

$$\text{Precision} = \frac{TP}{TP + FP}$$

Resim 6. Keskinlik (Precision) Hesaplanması

Kesinlik (Precision), positive olarak tahminlenen değerlerin gerçekten kaç tanesinin positive olduğunu göstermektedir. Kesinlik değeri özellikle false positive tahminlemenin maliyeti yüksek olduğu durumlarda çok önem taşımaktadır. Konfüzyon matrisinde yer alan değerlere göre modeldeki üç sınıfın keskinlik değerlerinin ortalaması alınarak elde edilmiş genel kesinlik oranının %80,75 olduğu görülmektedir.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Resim 7. Duyarlılık (Recall) Hesaplanması

Duyarlılık (Recall), positive durumların ne kadar başarılı tahmin edildiğini göstermektedir. Konfüzyon matrisinde yer alan değerlere göre modeldeki üç sınıfın duyarlılık değerlerinin ortalaması alınarak elde edilmiş genel duyarlılık oranının %74,00 olduğu görülmektedir. Elde edilen kesinlik ve duyarlılık değerlerinin harmonik ortalamasına göre F1 skoru %77,20 olarak sonuçlandırılmıştır.

CLASS	PRECISION	RECALL	F1-SCORE
BI-RADS0	0.9283	0.6426	0.7595
BI-RADS1-2	0.7414	0.9413	0.8295
BI-RADS4-5	0.7522	0.6463	0.6952

Resim 8. EfficientNet-B7 modelinin Sınıf Bazlı Metrik Değerleri

Modelden elde edilen sınıf bazlı metrik değerlerin oranları incelendiğinde Keskinlik metriğinde BI-RADS0 sınıfının diğer sınıflar ile kıyaslanması sonucu %92,83 ile daha iyi bir positive tahminleme oranına sahip olduğu görülmektedir. BI-RADS0 için Duyarlılık değerine bakıldığından ise 112 adet BI-RADS0 görüntüsünün BI-RADS1-2 sınıfı olarak tahmin edildiği ve 32 adet BI-RADS0 görüntüsünün BI-RADS4-5 sınıfı olarak tahmin edildiği görüлerek %64,26 ile en düşük duyarlılık değerine sahip olduğu anlaşılmaktadır. En yüksek duyarlılık değeri ise BI-RADS1-2 sınıfında %94,13 oranı ile elde edilmiştir. Bu durumdan anlaşılacağı üzere BI-RADS1-2 sınıfının görüntüleri modelimiz tarafından diğer sınıflara daha az benzetilerek daha başarılı bir tahmin sonucu ortaya çıkmıştır. Konfüzyon matrisi dikkatli bir şekilde incelendiğinde modelimizin en çok BI-RADS0 ile BI-RADS1-2 arasında ve BI-RADS1-2 ile BI-RADS4-5 sınıfları arasında karıştırmalar yaparak yanlış tahminlerde bulunduğu görülmektedir.

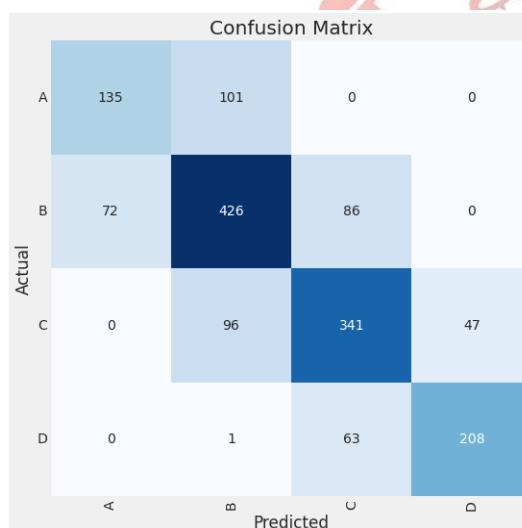
A	B	C	D	E	F	G	
1	HASTA NO	ResNet101	EffNetB7	EffNetB2	InceptionResNetV2	Ortak Sonuç	Gerçek Değeri
2	822670781	BI-RADS1-2	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5
3	825895818	BI-RADS1-2	BI-RADS4-5	BI-RADS1-2	BI-RADS1-2	BI-RADS1-2	BI-RADS1-2
4	836194037	BI-RADS0	BI-RADS0	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5	BI-RADS0
5	845283302	BI-RADS4-5	BI-RADS0	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5
6	822703281	BI-RADS1-2	BI-RADS0	BI-RADS4-5	BI-RADS1-2	BI-RADS1-2	BI-RADS1-2
7	836194179	BI-RADS0	BI-RADS1-2	BI-RADS0	BI-RADS1-2	BI-RADS0	BI-RADS0
8	845283882	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5
9	836194196	BI-RADS1-2	BI-RADS0	BI-RADS1-2	BI-RADS1-2	BI-RADS1-2	BI-RADS0
10	836186332	BI-RADS1-2	BI-RADS0	BI-RADS0	BI-RADS0	BI-RADS0	BI-RADS0
11	822696589	BI-RADS1-2	BI-RADS1-2	BI-RADS1-2	BI-RADS4-5	BI-RADS1-2	BI-RADS1-2
12	845280944	BI-RADS4-5	BI-RADS0	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5
13	825898433	BI-RADS1-2	BI-RADS1-2	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5	BI-RADS1-2
14	836163281	BI-RADS0	BI-RADS0	BI-RADS0	BI-RADS0	BI-RADS0	BI-RADS0
15	845281199	BI-RADS0	BI-RADS0	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5	BI-RADS4-5
16	822688702	BI-RADS1-2	BI-RADS1-2	BI-RADS0	BI-RADS0	BI-RADS0	BI-RADS1-2

Resim 9. Topluluk Öğrenmesi Modelinde Ortak Sonuçların Bulunması

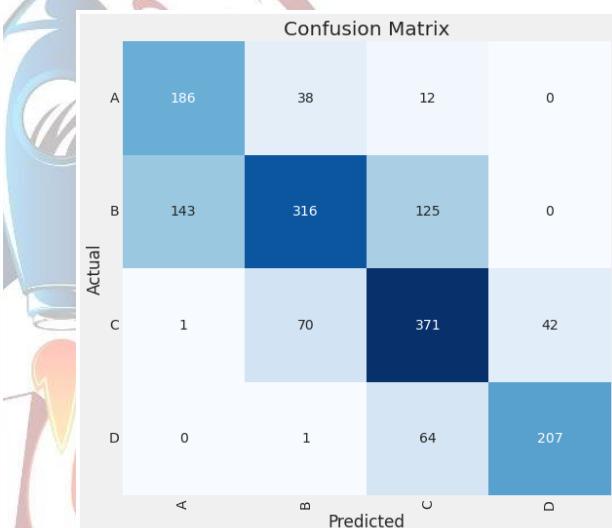
Topluluk öğrenmesi (Ensemble Learning); tek bir modele kıyasla doğruluk oranı daha yüksek ve genellenebilir sonuçlar elde etmek amacıyla birden fazla modelin tahmin sonuçlarını birleştirmektedir. Öğrenme aktarımı modellerinden ResNet101, EfficientNet-B2, EfficientNet-B7 ve InceptionResNetV2'nin kesinlik ve duyarlılık değerleri diğer modellerden daha yüksek başarı oranı sağladığından dört model birlikte kullanılarak topluluk öğrenmesi modeli oluşturulmuştur.

Topluluk öğrenmesi modelinde ortak sonuçlar bulunurken sırasıyla BI-RADS4-5, BI-RADS0 ve BI-RADS1-2 öncelik alma derecelendirilmesi yapılmıştır. Daha sonraki aşamada dört öğrenme aktarım modelinin tahmin sonuçları karşılaştırılmış ve en fazla tekrar edip öncelik derecesi en yüksek olanlar sonuçlar ortak sonuç olarak belirlenmiştir.

Öğrenme aktarımında EfficientNet-B2 modeli ile elde edilen en başarılı test sonucu olan 82,30 doğruluk değeri, topluluk öğrenmesi kullanılarak 86,78 değerine yükseltilmiştir. Bu durum neticesinde BI-RADS kategori tespitindeki başarı oranı %4,48 artırılarak daha başarılı bir model üretilmiştir.



Resim 10. EfficientNet Kompozisyonu



Resim 11. InceptionResNetV2 Kompozisyonu

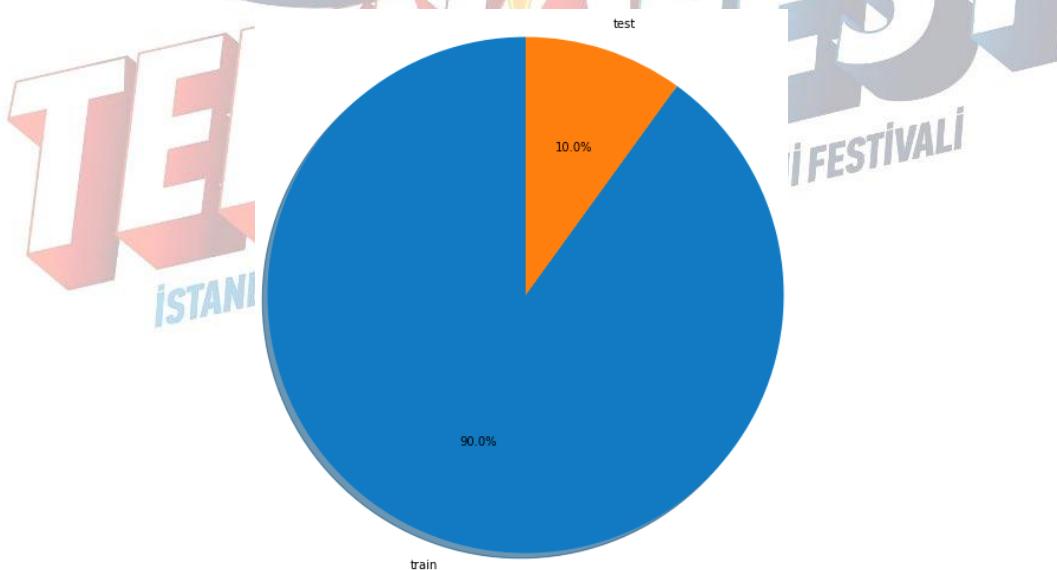
Kompozisyon kategori tespiti eğitimleri sonucu en başarılı olan iki model 70,43 değeri ile EfficientNet-B2 ve 68,52 değeri ile InceptionResNetV2 olmuştur. EfficientNet-B2 modelinde kesinlik ve duyarlılık metriklerinde başarısı en düşük olan sınıf A olmuştur. InceptionResNetV2 modelinde ise kesinlik metriğinde yine en düşük başarı sonucunu A sınıfı tahminlemesinde verirken duyarlılık metriğinde B sınıfı en düşük sonucu vermiştir. Kompozisyon kategori sınıflandırılması yapılrken veri setinde görüntü ekleme veya çıkarma işlemleri yapılmamıştır.

Kadran kategori tespiti yapılrken sadece BI-RADS0 ve BI-RADS4-5 kategorilerinin verileri kullanılmıştır. Yapılan eğitimin test sonuçlarında EfficientNet-B3 modeli üzerinde uygulanan özgün yöntemler ile 72,28 başarı oranı yakalanmıştır. Modelin tahminleme başarısı en düşük ALT-DIŞ sınıfında elde edilirken sınıfımanın en başarılı olduğu sınıf ise ÜST-DIŞ olmuştur. ALT-DIŞ sınıfının tahminlenmesindeki başarının düşük olmasında veri setinin çok az bir kısmının ALT-DIŞ verilerinden oluşmasının çok büyük bir etkisi olmuştur.

4. Deney ve eğitim aşamalarında kullanılan veri setleri

Yarışmada Teknofest tarafından sağlanan veri setine Kaggle'da devam eden RSNA Meme Kanseri Tespiti yarışmasının veri setinden eklemeler yapılmıştır. RSNA Tarama Mamografi Meme Kanseri Tespiti Veriseti, BI-RADS0 sınıfındaki veri sayısını diğer sınıflar ile dengelemek üzere kullanılmıştır. RSNA tüzüğünde ve Teknofest SYZ tarafından gerçekleştirilen soru-cevap toplantılarında belirtildiği üzere verilerin herkese açık olması ve yarışmanın tüm katılımcıları tarafından yarışma amacıyla eşit şekilde erişilebilir olması sağlanmıştır. Son olarak RSNA tüzüğünde; “Yarışma verilerini diğer yarışmalarda kullanabilme, Kaggle.com forumlarına katılabilme, akademik araştırma ve eğitim dahil olmak üzere ticari olmayan amaçlarla erişebilme ve bunları kullanabilme haklarına sahiptirler” şeklinde belirtilerek başka yarışmalarda kullanımına izin verilmiştir [5].

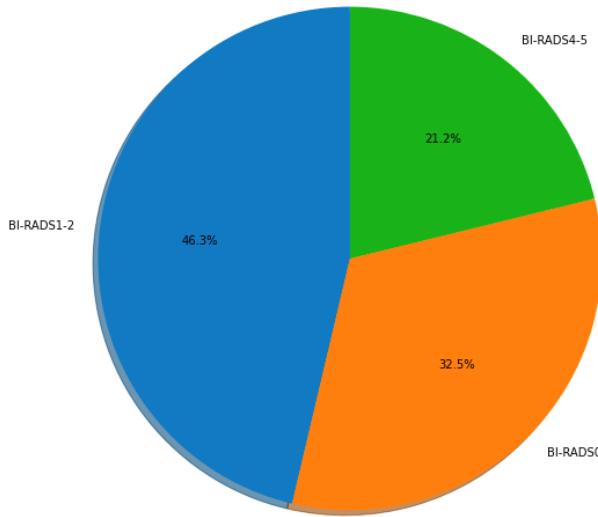
Deney ve eğitim aşamalarında veri setinin farklı senaryolarla değiştirilerek sonuçlara nasıl etki ettiği gözlemlenmiştir. Bu kısımda denemesi yapılan veri setleri şu şekilde sıralanabilir: Bütün veri sınıflarının eşit sayılarla eğitildiği veri seti, BI-RADS4-5 sınıfındaki kadransız verilerin dahil edilmediği veri seti, sadece BI-RADS0 sınıfındaki kadransız verilerin dahil edilmediği veri seti, BI-RADS0 sınıfına RSNA yarışma verilerinin dahil edilmesiyle elde edilen veri seti, BI-RADS1-2 sınıfında beraber bulunan 1 ve 2 kategorilerinin ayrılmasıyla oluşturulan 4 sınıfı veri seti, BI-RADS1-2 sınıfındaki kadranlı verilerin çıkarılmasıyla elde edilen veri seti, BI-RADS0 ve BI-RADS4-5 sınıflarına veri artırma işlemleri uygulanarak elde edilen veri seti ve son olarak bu senaryoların farklı kombinasyonlar ile beraber denemesi durumları gerçekleştirilmiştir. Buradaki en başarılı sonuç ise: BI-RADS0 sınıfındaki verilerin RSNA yarışma verileri kullanılarak artırılması, BI-RADS1-2 sınıfında herhangi bir değişikliğe gidilmemesi ve BI-RADS4-5 sınıfında ise kadransız verilerin veri setinden çıkarılması ile elde edilmiştir. Kadransız verilerin veri setinden çıkarılma sebebi ise görüntülerde hastalık belirtisinin olmamasından ötürü yapay zeka eğitiminin yanlış yapılmamasının istenmesidir.



Resim 12. Eğitim-Deney Verileri Dağılım Oranları

Eğitimleri gerçekleştirilen veri setinde Resim 12'den görüleceği üzere %90 Eğitim ve %10 Deney olacak şekilde veri ayırmaya işlemi yapılmıştır. Daha sonrasında ise ayrılan eğitim verisinin %10'u validasyon verisi olarak kullanılmıştır. Ayırma işlemi yapılrken bir hastanın görüntülerinin tümünün sadece eğitim kısmında ya da sadece deney kısmında olmasına özen gösterilmiştir. Bu şekilde ezberlemenin önüne geçilerek deney sonuçlarının daha gerçekçi

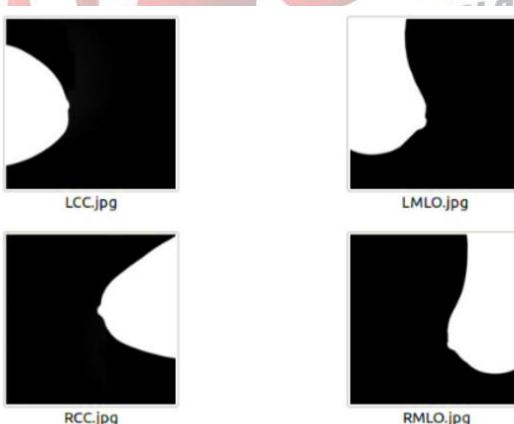
olması sağlanmıştır. Proje detay raporunun başarılı bir şekilde geçilmesi durumunda K-Fold Cross-Validation[6] yapılarak veri setindeki tüm veriler belirli sayıda parçalara ayrılacak ve bu durum neticesinde her verinin hem eğitim hem deney kısımlarında kullanılması sağlanacaktır .



Resim 13. Eğitim Verisi Dağılım Oranları

Eğitimleri gerçekleştirilen veri setindeki sınıfların yüzdesel veri dağılımı Resim 13'de gösterilmektedir. Tablodan görüldüğü üzere BI-RADS1-2 sınıfının diğer sınıflara oranla büyük bir veri üstünlüğü vardır, bu durum neticesinde eğitim sırasında BI-RADS1-2 sınıfına yönelik artmaka ve deney sonuçlarında BI-RADS1-2 tahmininin sıklıkla yapıldığı gözlemlenmektedir.

Kompozisyon bilgisinin sınıflandırılması, veri setinin A-B-C-D şeklinde 4 sınıfa ayrılması ile gerçekleştirilmiştir. Eğitim sırasında A sınıfından 2128 görüntü, B sınıfından 5156 görüntü, C sınıfından 4368 görüntü ve D sınıfından 2400 adet görüntü kullanılmıştır. Kadran bilgisinin sınıflandırılması gerçekleştirilirken BI-RADS0 ve BI-RADS4-5 kategorilerinden elde edilen ALT-DIŞ, ALT-İÇ, MERKEZ, ÜST-DIŞ ve ÜST-İÇ olmak üzere beş sınıf kullanılmıştır. Bu aşamada ÜST-DIŞ sınıfının 2581 görüntü ile diğer sınıflar üzerinde baskın bir özelliği vardır.



Resim 14. Veri Setindeki Gürültülü Veriler

Eğitime başlanmadan önce veri setinin içeriği görüntüler arasında Resim 14'te gösterildiği üzere hastalık teşhisini edilemeyecek ve tamamen siyah ya da beyaz görüntüler veri setinden temizlenmiştir.

5. Referanslar

[1]

https://hsgm.saglik.gov.tr/depo/birimler/kanser-db/yayinlar/sunular/mamografi_cekim_teknikleri_20.11.2019/BIRADS_0_Ne_Zaman_Kullanilim_Prof.Dr.Aysenur_Oktay.pdf

[2]

https://www.tensorflow.org/api_docs/python/tf/keras/applications

[3]

Khan, SanaUllah, et al. "A novel deep learning based framework for the detection and classification of breast cancer using transfer learning." Pattern Recognition Letters 125 (2019): 1-6.

[4]

<https://developers.google.com/machine-learning/crash-course/classification/precision-and-recall?hl=tr>

[5]

<https://www.kaggle.com/competitions/rsna-breast-cancer-detection/overview>

[6]

Roberts, David R., et al. "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure." Ecography 40.8 (2017): 913-929.

